

Perancangan Data Pipeline dan Implementasi Machine Learning untuk Analisis Performa Klub La Liga Musim 2023-2024

A. Latar Belakang

a. Evolusi Analisis Sepakbola

Industri olahraga pada saat ini mengalami pergeseran dari sekadar melihat skor akhir ke penggunaan *Event-Data Level* untuk analisis performa yang lebih objektif.

b. Kompleksitas Data Mentah

Dataset dari penyedia data (*Statsbomb*) memiliki format data yang kompleks. Volume data yang sangat besar dari berbagai pertandingan sepakbola tidak memungkinkan untuk diolah secara manual sehingga dibutuhkan *data pipeline* untuk melakukan transformasi agar data siap untuk dianalisis.

c. Fenomena Unik La-Liga


Pada musim 2023-2024 merupakan musim yang menarik secara taktis, terutama dengan munculnya klub papan tengah seperti Girona FC yang mendobrak dominasi klub papan atas. Terdapat celah antara hasil akhir klasemen dengan statistik permainan sebenarnya. Misalnya klub yang sering menang tetapi secara statistik *expected goals (xG)* rendah.

d. Kebutuhan *Analytics* dan *Machine Learning*

Membangun sistem yang mampu mengubah data mentah menjadi *dashboard* analisis performa dan model prediksi yang akurat. Analisis konvensional sulit memetakan gaya bermain tim secara otomatis.

B. Metodologi

Metodologi yang digunakan mengacu pada kerangka kerja *Data Engineering Lifecycle* secara *end-to-end*. Pendekatan ini dipilih untuk memastikan data mentah yang kompleks dapat diolah menjadi informasi yang akurat melalui tahapan-tahapan berikut.



Gambar *Data Engineering Life Cycle*

a. Generation (Sumber Data)

1. Penyedia Data

Sumber data berasal dari *Statsbomb Open Data* yang menyediakan data sepakbola dengan tingkat granularitas tinggi yang sering digunakan oleh klub profesional.

2. Ruang Lingkup (*scope*)

Data mencakup data kompetisi La-Liga pada musim 2023-2024 yang mencakup total 380 pertandingan.

3. Granularitas Data

Data tidak hanya berupa skor akhir, tetapi mencakup 3 level utama:

1. Match Data: Informasi makro seperti *manager*, stadion, dan jadwal pertandingan.
2. Lineup Data: Susunan pemain awal, posisi taktis
3. Event Data: Data paling detail yang mencatat setiap aksi di lapangan (*pass*, *shoot*, *dribble*, *intercept*, *etc*).

Data disediakan dalam format Nested JSON.

b. Ingestion (Pengambilan Data)

Bagian ini menjelaskan metode teknis bagaimana data tersebut dipindahkan ke dalam lingkungan kerja.

1. Metode Ingestion

Menggunakan pendekatan *Batch Ingestion*. Karena musim 2023-2024 sudah berakhir, data bersifat statis sehingga pengambilan data dilakukan sekaligus untuk satu musim penuh.

2. Tools

Proses pengambilan data dilakukan menggunakan *Python* dengan bantuan *library* seperti *statsbombpy/requests* untuk mengakses repositori resmi *StatsBomb*.

3. Landing Zone (Raw Storage)

Data hasil tarikan akan disimpan dalam format asli (JSON) untuk menjaga orisinalitas data sebelum masuk ke tahap transformasi.

c. Transformation (Pengolahan Data)

Tahap ini merupakan inti dari proses *data engineering* untuk mengubah data mentah menjadi *insightful data*.

1. Data Flattening

Data *StatsBomb* berbentuk *Nested JSON*, proses utama adalah melakukan ekstraksi objek bersarang menjadi format tabular (baris dan kolom).

2. Data Cleaning

a. Menangani *missing values*

b. Standardisasi

c. *Filter* data

3. Feature Engineering

Menciptakan kolom/metrik baru sebagai input analisis dan *Machine Learning*.

d. Storage (Penyimpanan Data)

1. *Bronze Layer*: Menyimpan data asli JSON (hasil *ingestion*)

2. *Gold Layer*: Menyimpan tabel hasil transformasi yang sudah bersih dan siap digunakan untuk Dashboard dan ML

e. Analytics & Visualization

- a. Menampilkan klasemen akhir (poin, kemenangan, kekalahan)
- b. Visualisasi akumulasi gol dan assist di seluruh pertandingan liga
- c. Menampilkan daftar pencetak gol terbanyak (top scorers) dan pemberi umpan terbanyak (top assists).
- d. Menghitung jumlah pertandingan tanpa kebobolan untuk penjaga gawang (clean sheets)
- e. Analisis statistik pemain bertahan berdasarkan jumlah intercept dan tackle
- f. Rekapitulasi pemain dan klub dengan akumulasi kartu kuning dan merah terbanyak
- g. Expected Goals (xG) vs Actual Goals League-wide

f. Machine Learning

menemukan pola tersembunyi dari data statistik yang tidak terlihat secara kasat mata.

- a. *Task*: Clustering
- b. Tujuan: Mengelompokkan klub berdasarkan identitas gaya bermain (*Tactical Identity*)
- c. *Fitur Input (Feature Selection)*: Menggunakan metrik hasil transformasi
 - i. *Possession Percentage* (Penguasaan bola)
 - ii. *Pass Accuracy* (Akurasi umpan)
 - iii. PPDA (*Passes Per Defensive Action*) untuk mengukur intensitas *pressing*
 - iv. *Average Shot Distance* (Rata-rata jarak tembakan)
- d. *Insight*: Terbentuknya kluster klub. Misalnya tim dominan menyerang/bertahan/serangan balik